

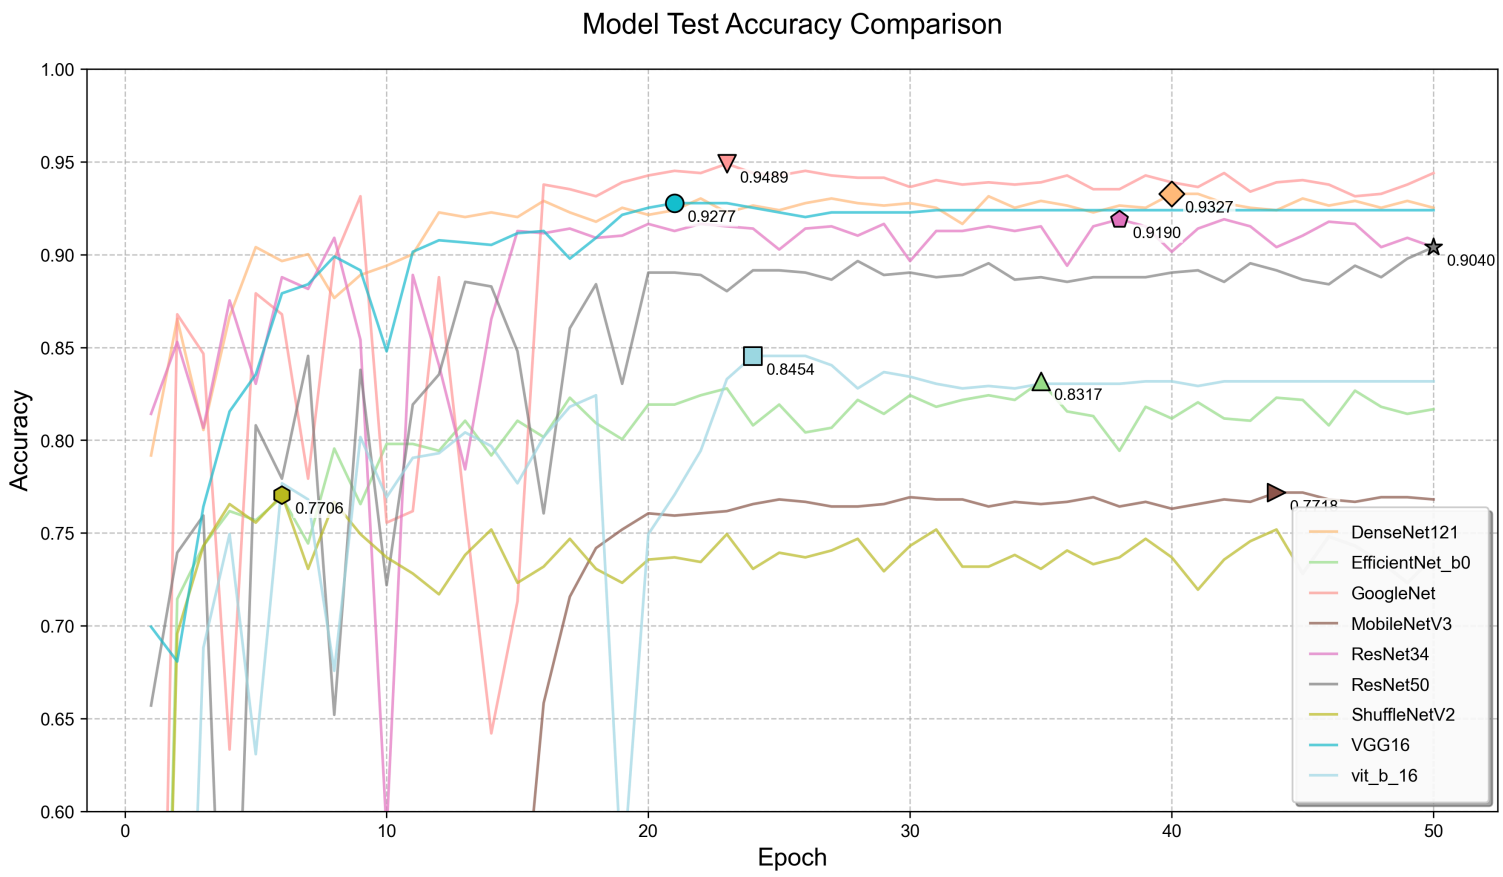
项目01：焊盘缺陷检测-工业缺陷分类实验记录表

主题	内容
实验阶段	基线模型对比 / 注意力机制 / 损失函数 / 在线离线数据增强 / 超参数微调
实验日期	2025.08.08 - 2025.08.25
核心目标	**1.漏检问题改善**：严重缺陷（如引线残留 CX、虚焊）的漏检率从基线模型的 X% 降至≤5%（以测试集真实缺陷样本为基准）漏检率 = 1 - 召回率（Recall）； **2.准确率指标：**总体检测准确率≥95%；严重缺陷（CX、HDZ、PW、XH2）类别准确率≥90%（精确率）； 严重缺陷召回率≥88%（确保少样本缺陷不被遗漏）； **3.泛化能力：**需结合新增 “复杂工况测试集”进行验证（不展开实验）
关键挑战	**1.脏数据清洗：** 问题：数据集中存在模糊图像、标注错误、重复样本； 应对：自动化筛选：用基线模型对原始数据预推理，标记 “模型无预测但标注有缺陷” 的疑似模糊样本，人工复核剔除； 标注校验：采用 “双标注 + 交叉审核”，对严重缺陷样本强制二次校验，修正错误标注； 去重处理：通过图像哈希值比对，删除重复样本。 **2.类别不平衡（CX:OK=1:151）：** 样本层面：对 CX 类样本进行 “过采样 + 合成”(如 StyleGAN ，暂时不考虑)； 算法层面：训练中采用 “动态权重”，结合 Focal Loss 抑制多数类主导，效果不明显（无变化）； 评估层面：以 “严重缺陷召回率” 为核心指标，弱化总体准确率权重，避免模型偏向多数类。
硬件	RTX 5090(32GB) * 1 、 25 vCPU Intel(R) Xeon(R) Platinum 8470Q
软件	PyTorch 2.8.0Python 3.12(ubuntu22.04)CUDA 12.8

1. 数据预处理记录

版本号	v1.0.0 初始版本	v1.1.1 初步清洗	v2.0.0 深度清洗
变更内容描述	保留原始采集数据	1.删除重复样本429张 2.删除错误标签214张 3.75.25划分数据	1.继续删除错误标签 2.对OK类进行欠采样（随机删除0.5） 3.80.20划分数据
样本总量	7,225	6,549	4004
类别分布	---------- 类别 数量 占比(%) ---------- CX 31 0.43% HDZ 779 10.78% OK 4686 64.86% PW 88 1.22% XH1 564 7.81% XH2 376 5.20% XH3 701 9.70%	---------- 类别 数量 占比(%) ---------- CX 28 0.43% HDZ 646 9.86% OK 4451 67.96% PW 61 0.93% XH1 515 7.86% XH2 244 3.73% XH3 604 9.22%	---------- 类别 数量 占比(%) ---------- CX 28 0.72% HDZ 585 14.61% OK 2123 53.02% PW 60 1.50% XH1 441 11.01% XH2 193 4.82% XH3 573 14.31%

2. 基线模型对比



参数设置

lr : 0.0001

batch size: 64

optimizer: AdamW

input: 140*173

dataset: v2.0.0

cirterion: CE

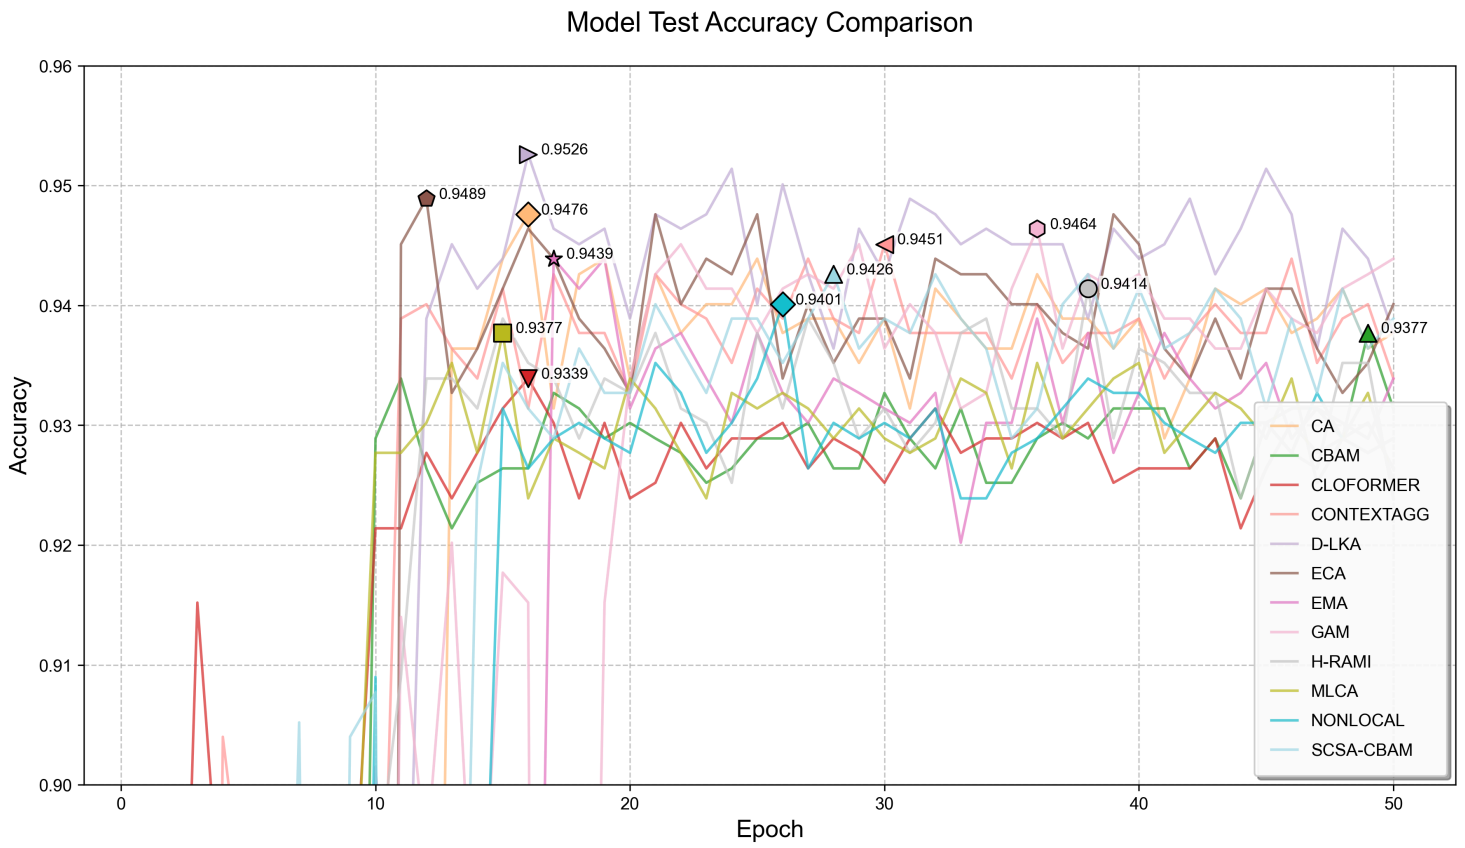
模型名称	总体准确率	CX	HDZ	OK	PW	XH1	XH2	XH3	参数量	推理速度(m	加权F1分数	混淆熵	陷召回率	Color Legend	
DenseNet1	0.932668	0.4	0.923077	0.976471	0.916667	0.842697	0.846154	0.904348	6961031	7.021434	0.931834	0.706109	0.771474		
EfficientNe	0.831671	0	0.641026	0.955294	0.666667	0.617978	0.435897	0.921739	4016515	3.646975	0.821715	1.245067	0.435897		
GoogleNe	0.94389	0.4	0.948718	0.978824	1	0.820225	0.897436	0.93913	9951413	3.145981	0.942727	0.5719	0.811538	0.00	
MobileNet	0.769327	0	0.615385	0.898824	0.166667	0.617978	0.205128	0.852174	1525031	2.28436	0.762446	1.473197	0.246795	0.20	
ResNet34	0.908978	0	0.931624	0.950588	0.75	0.730337	0.871795	0.93913	21288263	1.977596	0.905651	0.831759	0.638355	0.40	
ResNet50	0.90399	0.4	0.871795	0.955294	0.833333	0.797753	0.820513	0.886957	23522375	2.699838	0.903916	0.892445	0.73141	0.60	
ShuffleNet	0.765586	0	0.683761	0.901176	0	0.483146	0	0.93913	1260779	2.819629	0.735056	1.224271	0.17094	0.70	
VGG16	0.921446	0.4	0.923077	0.96	1	0.797753	0.794872	0.930435	1.34E+08	0.979707	0.92109	0.738627	0.779487	0.80	
vit_b_16	0.845387	0	0.803419	0.948235	0.083333	0.629213	0.538462	0.895652	85804039	4.668708	0.834608	1.17381	0.356303	1.00	

> 结论：GoogLeNet（无预训练）模型综合表现最佳，基于此模型进行后续消融实验。GoogLeNet 在严重缺陷类别（CX、HDZ、PW、XH2）中，平均漏检率达到 18.85%，其中CX漏检率达到 60%。下一步计划在 inception4b 后插入注意力机制，针对CX极少样本，低级特征做注意力增强，网络靠前位置进行选型attns。

3 模型结构增强对比：注意力机制类型、位置选择

机制名称	核心思想与特点	总体准确率提升	推理时间增加（ms）	加权F1分数
CA（通道注意力）	聚焦**通道维度**，通过全局池化+全连接学习通道权重，增强关键通道、抑制冗余通道。	94.76%	3.092978	0.946828
CBAM（卷积块注意力）	**串行融合通道+空间注意力**：先通道加权，再空间加权，双维度优化特征。	93.77%	3.096292	0.928774
CLOFORMER（卷积-Transformer融合）	结合**卷积的局部特征**与**Transformer的全局自注意力**，平衡局部细节与长距离依赖。	93.39%	3.350205	0.933812
D-LKA（动态局部关键注意力）	基于**局部关键区域，动态调整关注范围**（如根据特征自适应窗口大小），灵活捕捉局部关联。	**95.26%** **+0.37%**	3.216732	**0.952391** **+ 0.0096**
ECA（高效通道注意力）	用**自适应1D卷积**替代全连接，直接学习通道权重（无降维），极致优化效率。	94.89%	3.108511	0.944957
EMA（增强多尺度注意力，推测）	融合**多尺度特征**（如不同卷积核/金字塔结构），为每个尺度分配注意力权重。	94.36%	3.381159	0.942953
GAM（门控注意力）	引入**门控单元**（如sigmoid），动态控制注意力“开启/关闭”，精细筛选有效特征。	94.64%	3.313138	0.944919

机制名称	核心思想与特点	总体准确率提升	推理时间增加（ms）	加权F1分数
H-RAMI（层次化区域多尺度）	**层次化处理**（粗→细粒度）+ **多尺度分析**，模拟人类视觉分层认知，逐步聚焦关键区域。	94.14%	3.268592	0.937698
MLCA（多尺度局部通道）	结合**多尺度**（感受野）、**局部区域**、**通道注意力**，三重优化局部-全局特征。	93.77%	3.203163	0.936947
NONLOCAL（非局部注意力）	计算**每个位置与所有位置的关联**（全局依赖），强捕捉长距离关系（类似CV版自注意力）。	94.01%	3.233428	0.939719
SCSA-CBAM（空间-通道分离CBAM，推测）	**分离空间和通道的注意力计算**（如并行处理），再融合，增强维度针对性。	94.26%	3.068871	0.927735



参数设置

lr ：0.0001

batch size: 64

optimizer: AdamW

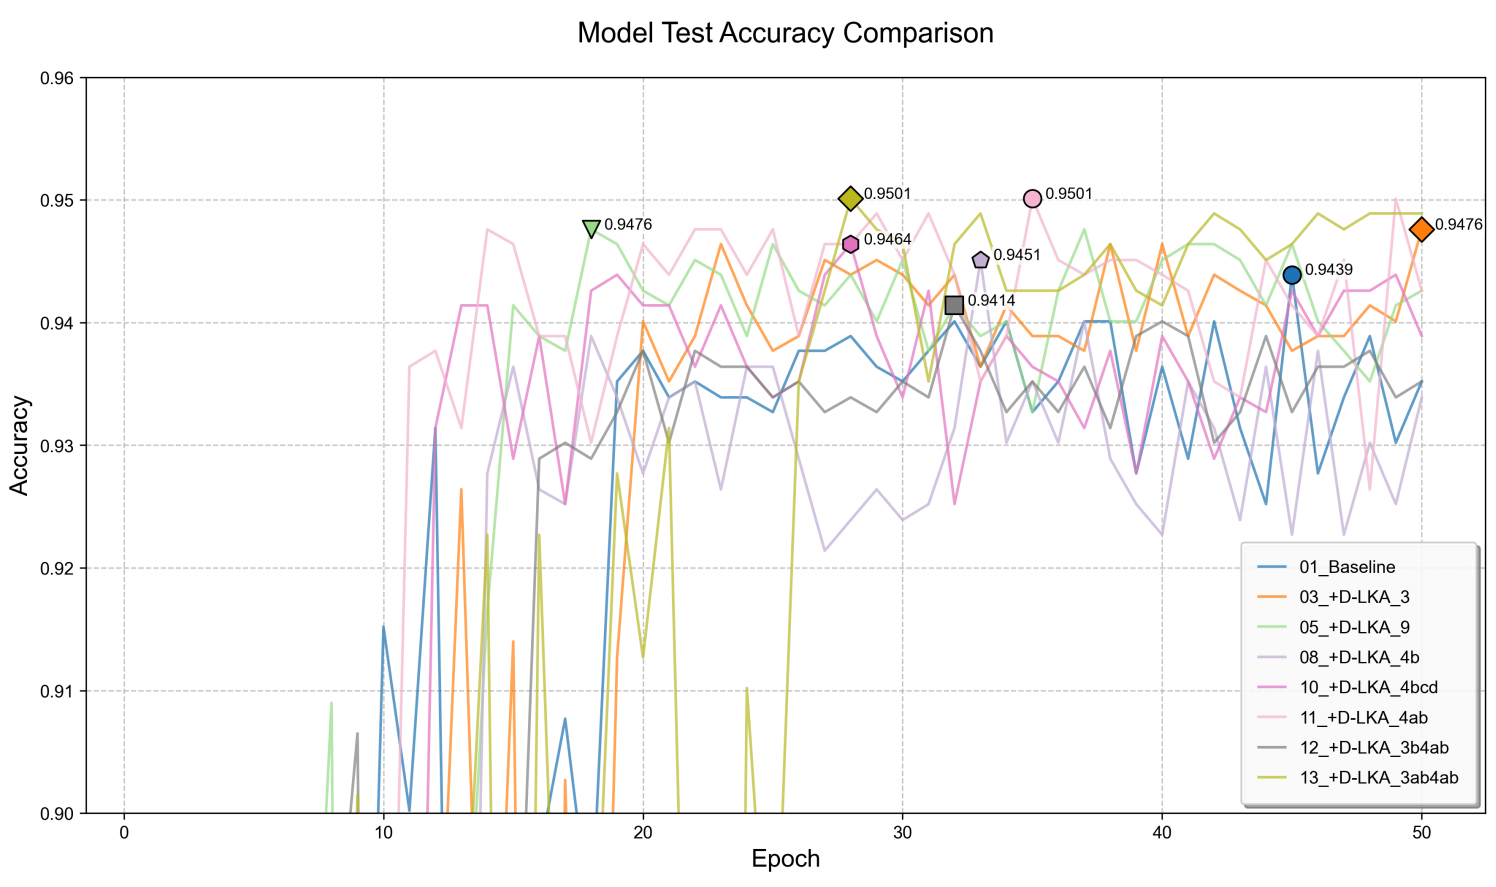
input: 140*173

dataset: v2.0.0

cirterion: CE

attns loc: 在 inception4b 后插入

结论：D-LKA 总体表现最佳。



参数设置

lr ：0.0001

batch size: 64

optimizer: AdamW

input: 140*173

dataset: v2.0.0

cirterion: CE

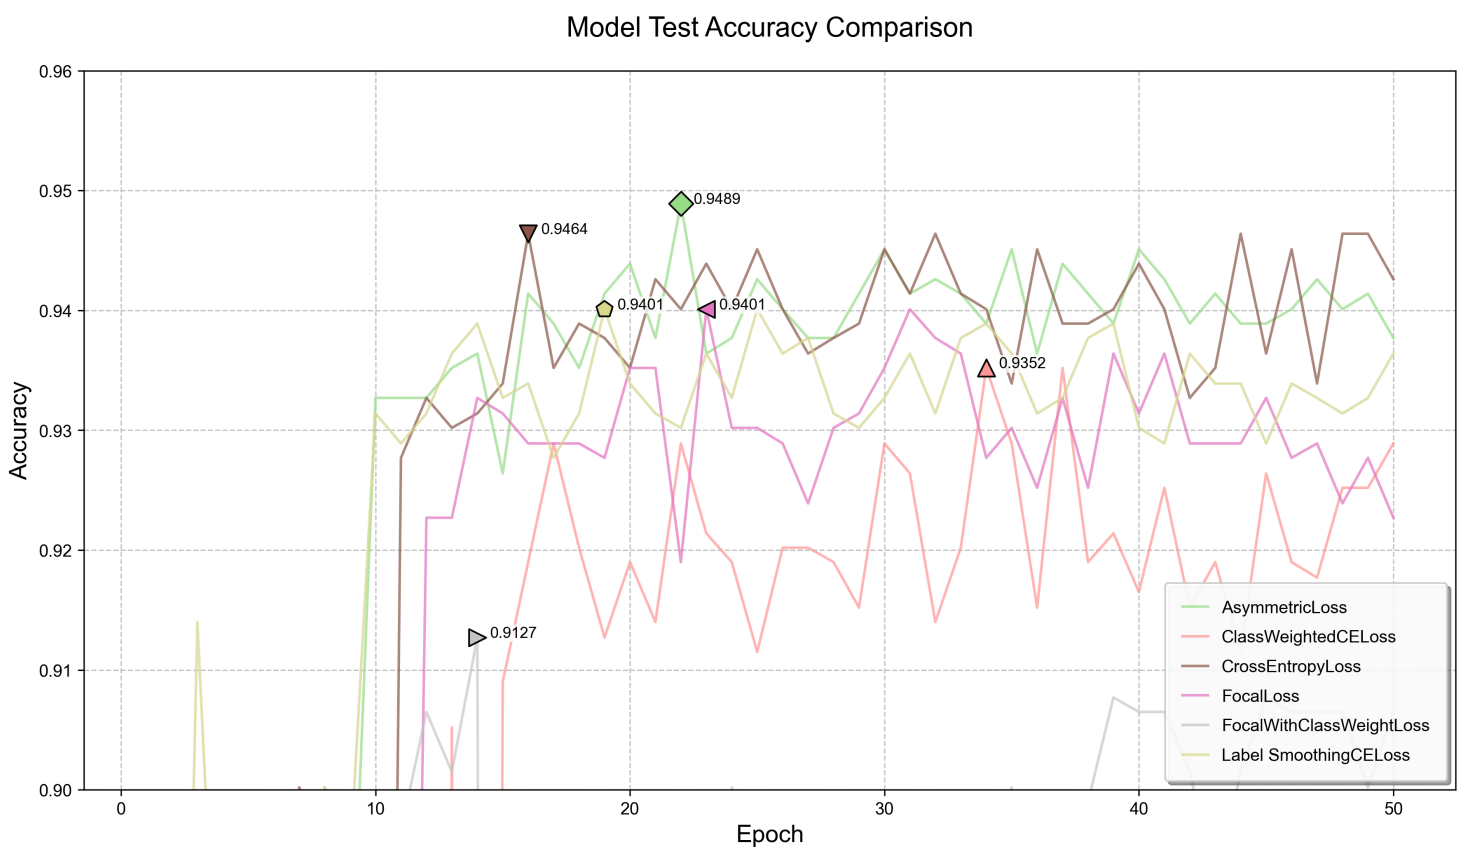
attns loc: 01-inception4b 后
03-inception后面三个
05-inception全部
08-..
..

> 在 GoogLeNet 的最开始 4 个 Inception 后面加注意力机制 （13_+D-LKA_3ab4ab）后发优势比较明显；初步推测注意力机制放在靠前位置（第一个inception）后增益明显。（后续使用13_+D-LKA_3ab4ab进行实验）

---

4 损失函数对比选择：

损失函数	主要特点	Accuracy（整体准确率）	核心优势场景
CrossEntropyLoss（标准交叉熵）	基础损失函数，无特殊优化； 适合类别平衡、样本难易分布均匀的场景； 不处理类别不平衡和难样本，少数类/难样本易被忽视。	**94.64%** **±0.00%**	类别平衡、样本简单
ClassWeighted（类别加权交叉熵）	通过类别权重缓解不平衡：给少数类更高权重，提升模型对少数类的关注； 仅优化类别不平衡，未区分样本难易（易样本仍可能主导损失）； 权重需根据样本分布预设（如按 inverse-frequency 计算）。	93.52%	仅类别不平衡（无大量难样本）
FocalLoss	聚焦难样本：通过 $(1-p_c)^\gamma$ 降低易样本（p_c高）的权重（γ越大，聚焦越强）； α_c可辅助处理类别不平衡； 适合存在大量易样本、难样本（如少数类样本）需重点优化的场景，需调优γ（通常取2）。	94.01%	大量难样本（类别较平衡）
FocalWithClassWeightLoss	综合优化：同时结合“类别加权”(处理不平衡）和“聚焦机制”(处理难样本)； 兼顾少数类关注和难样本挖掘，适合既不平衡又含大量难样本的场景； 需同时调优w_c和γ。	91.27%	类别不平衡+大量难样本（综合最优）
LSCE（标签平滑交叉熵）	软化标签防过拟合：将one-hot标签的“1”替换为$1-\varepsilon$、“0”替换为$\varepsilon/6$，避免模型对标签过度自信； 提升泛化能力，不直接处理类别不平衡； 适合数据量小、模型易过拟合的场景。	94.01%	模型过拟合（需提升泛化，不关注不平衡）
AsymmetricLoss（以不对称聚焦损失为例）	差异化处理正负样本错误：对“真实类别预测错误”(正类错误）和“非真实类别误判”(负类错误）设置不同惩罚权重（如少数类负类错误惩罚更低）； 适合“错误代价不对称”的场景（如少数类假阴性代价高于假阳性）； 需根据任务调优α,β,γ。	**94.89%** **+0.25%**	错误代价不对称（如少数类假阴性需规避）



参数设置

lr : 0.0001

batch size: 64

optimizer: AdamW

input: 140*173

dataset: v2.0.0

cirterion:
AsymmetricCrossEntropy
ClassWeightedCE
FocalLoss
Focal&ClassWeight
LabelSmoothingCE

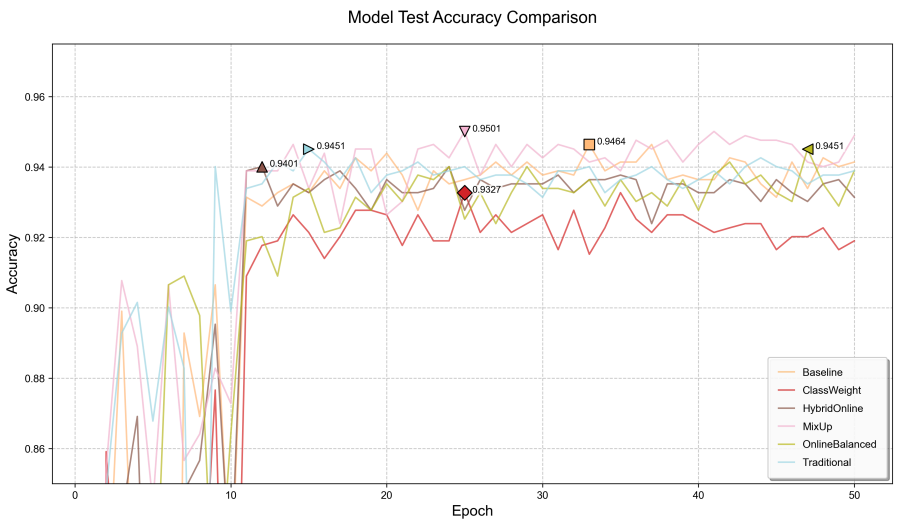
attns loc:
13_+D-LKA_3ab4ab

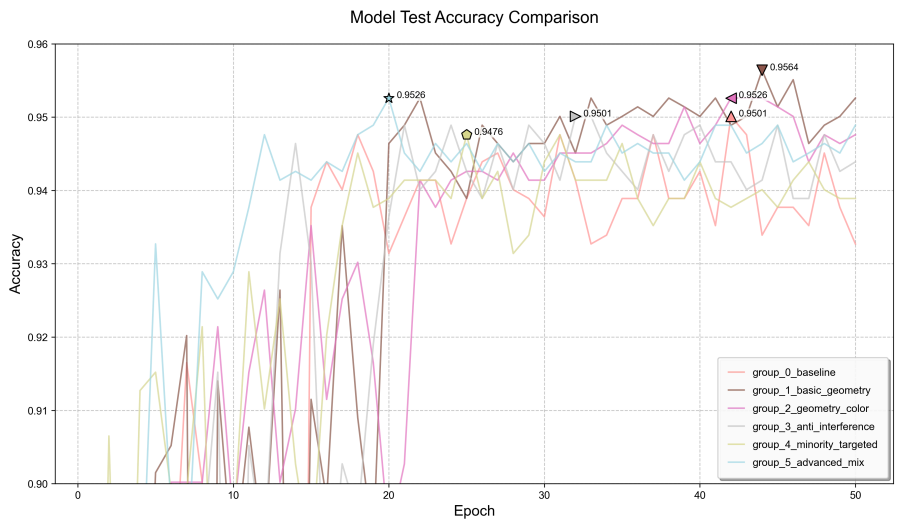
> 最高acc为94.89%（Asymmetric Loss），但是总体趋势和 Cross Entropy Loss 不相上下，先使用ASL进行后续实验，后续微调可再选取CE。

---

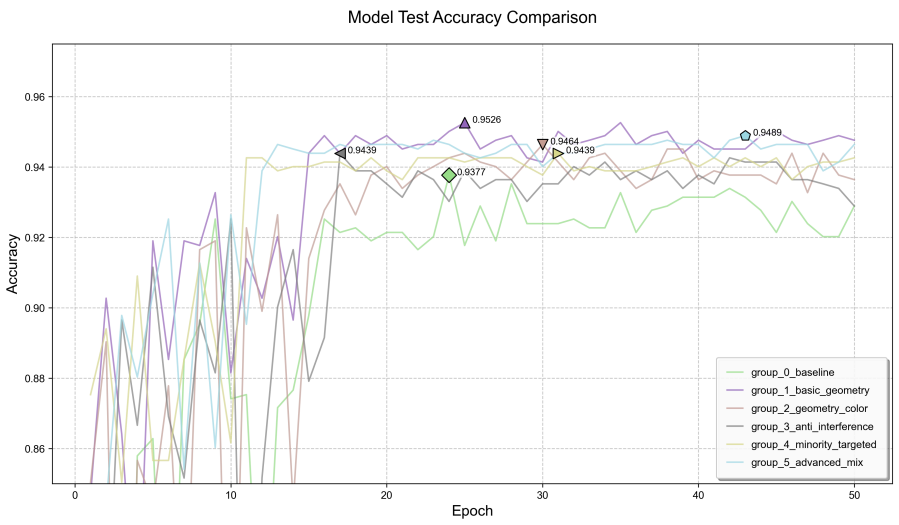
5 数据增强策略对比

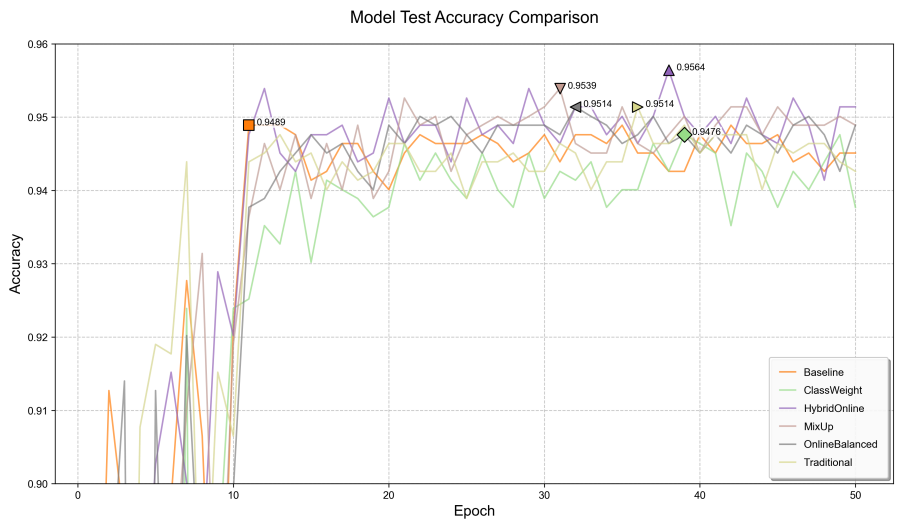
> 解决样本不均衡问题，提升模型对少数类缺陷的识别能力。 注：所有增强仅应用于训练集，验证集保持不变。





> 路线1：先做在线数据增强，选取acc最高的 MixUp ，在选取离线增强的消融实验，最高 acc 可达 95.64%（MixUp + basic_geometry）





> 路线2：先做离线数据增强，选取acc最高的 basic_geometry ，在选取在线增强的消融实验，最高 acc 可达 95.64%（basic_geometry + HybirdOnline）

5.1 数据增强策略对比：在线数据增强

实验组	增强策略	关键参数说明	主要目的
Baseline	无增强（仅标准化）	标准化参数：使用训练集计算的均值（如RGB三通道均值）和标准差（如RGB三通道标准差），对输入图像进行归一化（x = (x - mean) / std）。	作为基准对照组，排除任何数据增强的影响，评估模型在原始数据上的基础性能（准确率、漏检率等）。
Traditional	轻微几何增强	- 旋转：±5°（图像绕中心旋转范围为顺时针5°至逆时针5°，边缘采用填充策略保持尺寸）；	通过小幅度几何变换增加数据多样性，提升模型对目标轻微形变、位置偏移的鲁棒性，避免过度增强导致特征

实验组	增强策略	关键参数说明	主要目的
		- 平移：±5%（图像沿x/y轴平移，平移距离为自身宽/高的5%以内）。	失真。
MixUp	在线MixUp混合	α=0.2（MixUp混合系数服从Beta(α, α)分布，α=0.2时混合比例更偏向原始样本，避免过度混合导致特征模糊）；混合方式为随机选取两张样本按比例加权融合。	通过样本间特征混合增强，缓解类别不平衡问题，提升模型对边缘样本（如模糊、低对比度样本）的泛化能力，减少极端样本漏检。
OnlineBalanced	类平衡采样+轻微几何增强	- 采样权重：基于训练集类别频率计算，权重=1/类别样本数（少数类权重更高，如CX类权重为OK类的151倍）； - 几何增强参数同Traditional组。	优先解决类别不平衡（如CX:OK=1:151），通过平衡采样让模型更多学习少数类特征，结合几何增强进一步提升对少数类形变的适应能力。
ClassWeight	损失函数加权	权重计算：基于类别频率动态生成，权重=总样本数/(类别数×该类样本数)（少数类权重更高），直接作用于损失函数（如交叉熵损失），放大少数类损失的优化占比。	通过损失加权强制模型关注少数类，解决因样本量差异导致的“多数类主导优化”问题，提升少数类（如严重缺陷）的识别精度。
HybridOnline	轻微几何增强+在线MixUp	- 几何增强参数同Traditional组；- MixUp参数同MixUp组（α=0.2），增强流程为“先几何变换，后MixUp混合”	结合空间变换（几何增强）和样本分布增强（MixUp）的优势，从“目标形态多样性”和“样本特征多样性”两方面提升模型鲁棒性，尤其针对复杂场景下的漏检问题。

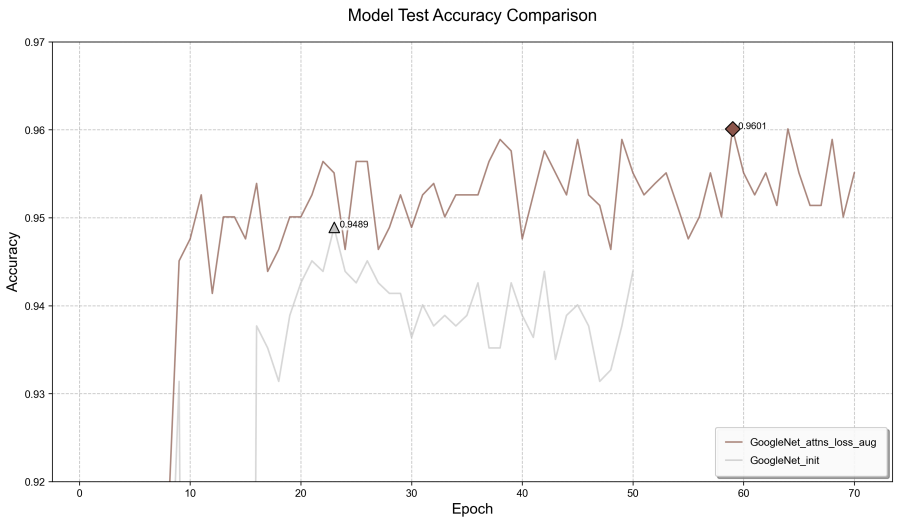
5.2 数据增强策略对比：离线数据增强

组号	组名（策略）	核心增强方法	增强细节（参数）	样本量处理	主要目的
0	Baseline	对照组：无任何增强	-	原始训练集（不扩充）	作为基准，衡量增强方法的有效性
1	basic_geometry	基础几何变换组：仅几何变换（不破坏缺陷特征）	- 旋转：-10°~+10°（随机角度，步长5°） - 平移：水平/垂直±5%图像尺寸（保留完整缺陷） - 水平翻转：50%概率（对称场景）	每个原始样本生成2个增强样本（总样本量=原始×3）	验证几何变换对模型抗角度/位置偏差能力的提升
2	geometry_color	几何+颜色变换组：几何变换+光照/颜色调整	- 继承组1的几何变换 - 亮度：0.7~1.3倍原始亮度 - 对比度：0.8~1.2倍原始对比度	每个原始样本生成3个增强样本（总样本量=原始×4）	验证光照/颜色鲁棒性对分类性能的影响
3	anti_interference	抗干扰增强组：几何+颜色变换+轻微噪声/模糊	- 继承组2的变换 - 高斯噪声：方差0.005~0.01（低强度） - 高斯模糊：3×3核（轻微失焦模拟）	每个原始样本生成3个增强样本（总样本量=原始×4）	验证模型对传感器噪声、轻微失焦等干扰的容错性
4	minority_targeted	少数类针对性增强组：多数类常规增强+少数类额外增强（缓解不平衡）	- 多数类（如“OK”）：继承组2策略（每个样本生成2个增强样本） - 少数类（如“CX”“PW”）：组2基础上增加随机裁剪（保留缺陷）+剪切（-5°~+5°），每个样本生成5个增强样本	增强后所有类别样本量差异≤20%（如多数类10000→少数类≥8000）	验证针对性增强对少数类识别性能的提升
5	advanced_mix	高级混合增强组：基础变换+高级增强（混合样本生成）	- 继承组2的变换 - Cutmix：随机裁剪10%~30%区域（粘贴其他图像缺陷区域，标签按比例混合） - 随机擦除：遮挡5%~10%非缺陷区域	每个原始样本生成4个增强样本（总样本量=原始×5）	验证复杂增强对模型学习全局特征和边界样本的帮助

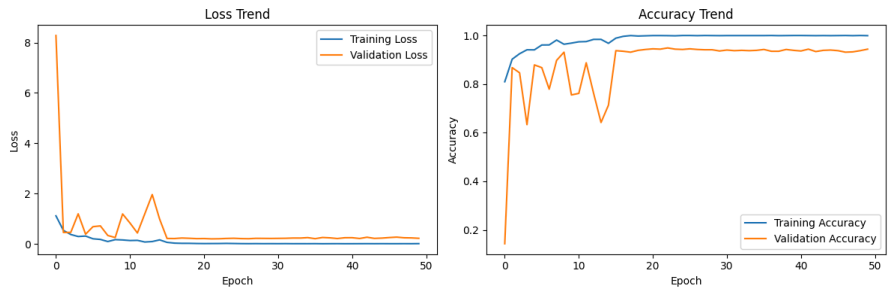
6. 初始与最终优化性能

> 在其他未展示的实验中发现模型有不稳定现象，加大epoch再进行训练

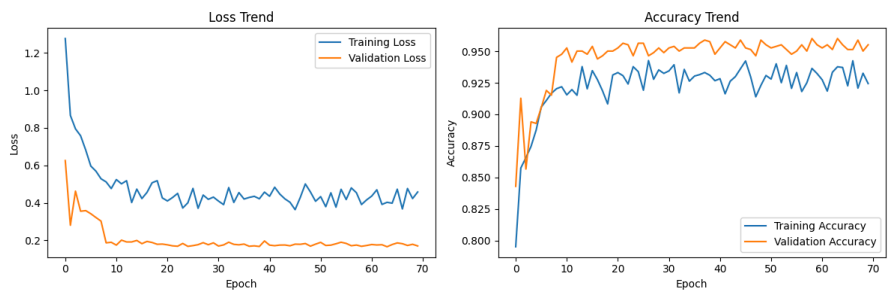
名称	总体acc	CX	HDZ	OK	PW	XH1	XH2	XH3	参数量	理速度(m	加权F1分数	混淆熵	陷召回率	CX	PW	HDZ	XH2
GoogleNet_attns_loss_aug	0.9601	0.8	0.974359	0.976471	0.833333	0.932584	0.948718	0.930435	10861397	3.206472	0.960419	0.431964	0.889103	0.8	0.833333	0.974359	0.948718
GoogleNet_init	0.94389	0.4	0.948718	0.978824	1	0.820225	0.897436	0.93913	9951413	3.145981	0.942727	0.5719	0.811538	0.4	1	0.948718	0.897436



模型	指标	CX	HDZ	OK	PW	XH1	XH2	XH3	macro avg	eighted av
GoogleNet_attns_loss_aug	precision	1	0.9268	0.9834	0.8333	0.8646	1	0.9907	0.9427	0.9617
	recall	0.8	0.9744	0.9765	0.8333	0.9326	0.9487	0.9304	0.9137	0.9601
	f1-score	0.8889	0.95	0.9799	0.8333	0.8973	0.9737	0.9596	0.9261	0.9604
	support	5	117	425	12	89	39	115	802	802
GoogleNet_init	precision	1	0.9024	0.9674	0.9231	0.9359	0.875	0.931	0.9336	0.9443
	recall	0.4	0.9487	0.9788	1	0.8202	0.8974	0.9391	0.8549	0.9439
	f1-score	0.5714	0.925	0.9731	0.96	0.8743	0.8861	0.9351	0.875	0.9427
	support	5	117	425	12	89	39	115	802	802



GoogleNet_init 初始的训练趋势



GoogleNet_attns_loss_aug 的训练趋势：acc ↑ + 泛化强

7. 实验结论与迭代计划

1. 最优方案：Googlenet + D-LKA_3ab4ab + ASL + 在线MixUp + 离线basic_geometry扩增样本
   → 达到 总体 94.89%（初始） → 96.01 %（优化） ACC
2. 待优化：
   - 继续增加CX、PW的真实样本，再进行优化
   - （CX类80%）CX的测试集数量一共只有5张；（PW类83.33%）PW的测试集数量一共只有12张；（删除数据集之后的结果）

💡 summary: **capybara** is all you need.